

Lista 2

Enunciado

- Modelo estatístico: $X_i|\theta \sim \text{Ber}(\theta)$, $i = 1, 2, \dots$, v.a.i.;
- Priori: $\theta \sim \text{Beta}(a, b)$;
- Item 1: Determine a *posterior predictive distribution*;
- Item 2: Determine $E[\tilde{X} = \tilde{x}|\mathbf{X} = \mathbf{x}]$, $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$;
- Item 3: Sugira um procedimento para determinar os hiperparâmetros a e b ;
- Item 4: Obter o estimador de Bayes de $1/\theta$.

Resolução

Item 1

Seja $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$ o vetor dos dados observados e \tilde{x} uma observação futura. Para calcularmos a distribuição preditiva a posteriori $p(\tilde{x}|\mathbf{x})$, necessitamos primeiramente calcular a distribuição a posteriori de θ , $p(\theta|\mathbf{x})$.

Distribuição a posteriori de θ

A distribuição a posteriori $p(\theta|\mathbf{x})$ é obtida pela fórmula de Bayes:

$$p(\theta|\mathbf{x}) = \frac{p(\mathbf{x}|\theta)p(\theta)}{p(\mathbf{x})}, \quad (1)$$

onde $p(\mathbf{x}|\theta)$ é a função de verossimilhança, $p(\theta)$ é a distribuição a priori e $p(\mathbf{x})$ é a probabilidade total a priori (*prior predictive probability*).

A função de verossimilhança é obtida à partir do modelo estatístico:

$$p(\mathbf{x}|\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{(1 - x_i)} \quad (2)$$

Para facilitar os cálculos, seja $T = \sum_{i=1}^n x_i$. Podemos, re-escrever a eq. (4) como

$$p(\mathbf{x}|\theta) = \theta^T (1 - \theta)^{(n-T)}. \quad (3)$$

Por sua vez, a função de densidade da priori é

$$p(\theta) = c\theta^{a-1}(1-\theta)^{b-1} \quad (4)$$

sendo $c = B(a, b)$ a constante de normalização, onde $B(a, b)$ é a função beta. Com isso, a posteriori fica

$$p(\theta|\mathbf{x}) = \left(\frac{c}{p(\mathbf{x})}\right) \theta^{T+a-1}(1-\theta)^{n-T+b-1} \quad (5)$$

$$(6)$$

Calculando agora $p(\mathbf{x})$:

$$p(\mathbf{x}) = \int_0^1 p(\mathbf{x}|\theta)p(\theta)d\theta \quad (7)$$

$$= \int_0^1 [\theta^T(1-\theta)^{n-T}] [c\theta^{a-1}(1-\theta)^{b-1}] d\theta \quad (8)$$

$$= c \int_0^1 \theta^{T+a-1}(1-\theta)^{n-T+b-1} d\theta \quad (9)$$

$$= cB(T+a, n-T+b) \quad (10)$$

Então, a distribuição a posteriori $p(\theta|\mathbf{x})$ fica

$$p(\theta|\mathbf{x}) = \frac{\theta^{T+a-1}(1-\theta)^{n-T+b-1}}{B(T+a, n-T+b)} \quad (11)$$

De onde notamos que trata-se da própria distribuição Beta, mas com parâmetros atualizados:

$$\theta|\mathbf{x} \sim \text{Beta}(T+a, n-T+b). \quad (12)$$

Distribuição preditiva a posteriori

Seja \tilde{x} uma observação futura (um único ponto). Observe que \tilde{x} é uma v.a. de Bernoulli. A distribuição preditiva a posteriori é dada por:

$$p(\tilde{x} = 1|\mathbf{x}) = \int_0^1 p(\tilde{x} = 1|\theta, \mathbf{x})p(\theta|\mathbf{x})d\theta \quad (13)$$

$$p(\tilde{x} = 0|\mathbf{x}) = \int_0^1 p(\tilde{x} = 0|\theta, \mathbf{x})p(\theta|\mathbf{x})d\theta \quad (14)$$

$$= 1 - p(\tilde{x} = 1|\mathbf{x}) \quad (15)$$

Para calcularmos $p(\tilde{x} = 1|\mathbf{x})$, adotamos a premissa de que \tilde{x} é condicionalmente independente de \mathbf{x} na presença de θ ($\tilde{x} \perp \mathbf{x} \mid \theta$). Então:

$$p(\tilde{x} = 1|\mathbf{x}) = \int_0^1 p(\tilde{x} = 1|\theta)p(\theta|\mathbf{x})d\theta \quad (16)$$

$$= \int_0^1 [\theta] \left[\frac{\theta^{T+a-1}(1-\theta)^{n-T+b-1}}{B(T+a, n-T+b)} \right] d\theta \quad (17)$$

$$= \frac{1}{B(T+a, n-T+b)} \int_0^1 \theta^{T+a}(1-\theta)^{n-T+b-1} d\theta \quad (18)$$

$$= \frac{B(T+a+1, n-T+b)}{B(T+a, n-T+b)} \quad (19)$$

$$(20)$$

Item 2

Como \tilde{x} é uma v.a. de Bernoulli, a esperança de $\tilde{x}|\mathbf{x}$ é dada pelo próprio valor de $p(\tilde{x} = 1|\mathbf{x})$, o qual já foi calculado no item anterior:

$$E[\tilde{x} | \mathbf{x}] = 1 \times p(\tilde{x} = 1|\mathbf{x}) + 0 \times p(\tilde{x} = 0|\mathbf{x}) \quad (21)$$

$$= p(\tilde{x} = 1|\mathbf{x}) \quad (22)$$

$$= \frac{B(T+a-1, n-T+b)}{B(T+a, n-T+b)} \quad (23)$$

$$(24)$$

Item 3

De acordo com Lehman e Casella (seção 4.1, pg. 232), embora o estatístico bayesiano subjetivo talvez não consiga expressar a priori precisamente, ele geralmente possui uma ideia do formato da função densidade: ela pode ser simétrica, assimétrica, com formato “L” ou “U”. Então, os parâmetros a e b podem ser ajustados com o intuito de buscar esta forma da função densidade. Além da forma, se o estatístico tiver uma ideia do valor esperado e da variância da distribuição, é possível ajustar a e b de forma que a distribuição tenha estes valores.

Uma ideia similar, sugerida por Berger (Cap. 3, pg. 64) é selecionar o(s) ponto(s) com valores mais plausíveis e "menos plausíveis", e então determinar, quais as chances (*odds*) relativas destes pontos, buscando novamente esboçar uma forma para a distribuição a priori.

Item 4

Vamos obter o estimador de Bayes de $1/\theta$ através da definição de valor esperado:

$$E[1/\theta] = \int_0^1 \frac{1}{\theta} p(\theta|\mathbf{x}) d\theta \quad (25)$$

$$= \int_0^1 \frac{1}{\theta} \frac{\theta^{T+a-1}(1-\theta)^{n-T+b-1}}{B(T+a, n-T+b)} d\theta \quad (26)$$

$$= \frac{1}{B(T+a, n-T+b)} \int_0^1 \theta^{T+a-2}(1-\theta)^{n-T+b-1} d\theta \quad (27)$$

$$= \frac{B(T+a-1, n-T+b)}{B(T+a, n-T+b)} \quad (28)$$