

ALUNO: CLEITON MOYA DE ALMEIDA
EST5104 - INFERÊNCIA BAYESIANA
PROF. JOSEMAR RODRIGUES
14/04/2025

Lista 3 (continuação da Lista 2)

Enunciado

- Modelo estatístico: $X_i|\theta \sim \text{Ber}(\theta)$, $i = 1, 2, \dots$, v.a.i.;
- Priori: $\theta \sim \text{Beta}(a, b)$;
- Seja $\tilde{T} = \sum_1^{50} \tilde{X}_i$, $T = \sum_1^{100} X_i = 8$, $a = 9$, $b = 90$;
- Item 1: Determine a densidade preditiva de \tilde{T} ;
- Item 2: Determine o EMV de θ e a moda a posteriori;
- Item 3: Compare graficamente a densidade preditiva de \tilde{T} com $\tilde{T} \sim \text{Bin}(50, \hat{\theta})$, onde $\hat{\theta}$: EMV (clássica). Comente esta comparação.
- Item 4: O que acontece quando utilizamos $a = b = 1$?

Resolução

Item 1

Vamos chamar $n = 100$ e $\tilde{n} = 50$. Para calcularmos a densidade preditiva, necessitamos novamente da densidade a posteriori de θ . Esta densidade já foi determinada na lista anterior (Lista 2):

$$p(\theta|\mathbf{x}) = \frac{\theta^{T+a-1}(1-\theta)^{n-T+b-1}}{B(T+a, n-T+b)}. \quad (1)$$

Calculamos a distribuição preditiva através da seguinte integral:

$$p(\tilde{T} = \tilde{t}|\mathbf{x}) = \int_0^1 p(\tilde{T} = \tilde{t}|\theta, \mathbf{x})p(\theta|\mathbf{x})d\theta. \quad (2)$$

Novamente usando a suposição de que \tilde{T} é condicionalmente independente de \mathbf{X} na presença de θ ($\tilde{T} \perp \mathbf{X} \mid \theta$), temos:

$$p(\tilde{T} = \tilde{t}|\mathbf{x}) = \int_0^1 p(\tilde{T} = \tilde{t}|\theta)p(\theta|\mathbf{x})d\theta. \quad (3)$$

Agora, \tilde{T} conta o número de sucessos em \mathbf{X} ($\tilde{T} = \sum \tilde{X}_i$), então \tilde{T} segue uma distribuição Binomial:

$$p(\tilde{T} = \tilde{t}|\theta) = \binom{\tilde{n}}{\tilde{t}} \theta^{\tilde{t}} (1 - \theta)^{\tilde{n} - \tilde{t}}. \quad (4)$$

Então, a distribuição preditiva fica

$$p(\tilde{T} = \tilde{t}|\mathbf{x}) = \int_0^1 p(\tilde{T} = \tilde{t}|\theta)p(\theta|\mathbf{x})d\theta \quad (5)$$

$$= \int_0^1 \left[\binom{\tilde{n}}{\tilde{t}} \theta^{\tilde{t}} (1 - \theta)^{\tilde{n} - \tilde{t}} \right] \left[\frac{\theta^{T+a-1} (1 - \theta)^{n-T+b-1}}{B(T+a, n-T+b)} \right] d\theta \quad (6)$$

$$= \binom{\tilde{n}}{\tilde{t}} \int_0^1 \frac{\theta^{T+\tilde{t}+a-1} (1 - \theta)^{n+\tilde{n}-(T+\tilde{t})+b-1}}{B(T+a, n-T+b)} d\theta \quad (7)$$

$$= \binom{\tilde{n}}{\tilde{t}} \frac{B(T+\tilde{t}+a, n+\tilde{n}-(T+\tilde{t})+b)}{B(T+a, n-T+b)}. \quad (8)$$

Item 2

Estimador EMV

A função de verossimilhança é dada por

$$\mathcal{L}(\theta|\mathbf{x}) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} \quad (9)$$

$$= \theta^T (1 - \theta)^{n-T} \quad (10)$$

Como X_i segue a distribuição de Bernoulli, sabemos que o estimador de máxima verossimilhança (EMV) é dado por

$$\hat{\theta}_{\text{emv}} = \frac{T}{n} = \frac{8}{100} = 0.08 \quad (11)$$

Moda a posteriori

Como $\theta|\mathbf{x} \sim \text{Beta}(\alpha, \beta)$, com $\alpha = T + a$ e $\beta = n - T + b$, temos

$$\hat{\theta}_{\text{map}} = \frac{\alpha - 1}{\alpha + \beta - 2} \quad (12)$$

$$= \frac{T + a - 1}{n + a + b - 2} = \frac{16}{197} \approx 0.0812 \quad (13)$$

Verificamos que os dois estimadores (EMV e MAP) possuem valores bem próximos, sendo que $\hat{\theta}_{\text{map}}$ está ligeiramente à direita de $\hat{\theta}_{\text{emv}}$. Isto ocorre devido à influência da priori.




Figura 1: Distribuição preditiva a posteriori (em vermelho) e distribuição binomial com $\hat{\theta}_{emv}$ (em preto). Observe que ambas distribuições possuem o mesmo máximo em $\tilde{t} = 4$, porém a binomial é um pouco mais concentrada neste ponto.

Item 3

Na fig. 1, plotamos a distribuição preditiva a posteriori $p(\tilde{T} = \tilde{t}|\mathbf{x})$ (em vermelho) e a distribuição binomial com $\hat{\theta}_{emv}$ (em preto) para 50 observações futuras. Observamos que as duas distribuições apresentam formatos bastante semelhantes, além do mesmo ponto de máximo ($\tilde{t} = 4$). Este ponto previsto de máxima probabilidade era esperado, pois a proporção estimada de sucessos (tanto pelo EMV quando MAP) foi em torno de 0.08 (no caso do EMV, exatamente 0.08). Portanto, em uma janela de 50 observações futuras, esperamos $50 \times 0.08 = 4$ ocorrências de $X = 1$.

Porém, a distribuição binomial apresenta a massa um pouco mais concentrada (pico um pouco maior) em torno da moda. Isto significa que a escolha da priori acrescentou uma incerteza (variância) adicional em torno da moda.

Item 4

No item 4, analisamos os resultados quando utilizarmos os hiperparâmetros $a = b = 1$. Notamos que, com esta configuração, a distribuição beta é equivalente à distribuição uniforme com intervalo $[0, 1]$.

Para melhor entendemos e visualizarmos os resultados, adotamos 3 configurações de priors:

- Priori 1: $a = 9$, $b = 90$ (moda: $\theta = 8/97 \approx 0.082$);
- Priori 2: $a = 21$, $b = 81$ (moda: $\theta = 0.2$);
- Priori 3: $a = 1$, $b = 1$ (distribuição uniforme).




Figura 2: Distribuições a priori e respectivas posteriores. Priori 1: $a = 9$, $b = 90$; Priori 2: $a = 21$, $b = 81$; Priori 3: $a = 1$, $b = 1$. Note que as posteriores 1 e 3 são semelhantes, enquanto a Posteriori 2 possui a moda “puxada” para a direita devido à influência da priori.

Primeiramente, notamos que, com $a = 1$, $b = 1$, o valor da moda a posteriori coincide com o valor da estimativa de máxima verossimilhança:

$$\hat{\theta}_{\text{map}_3} = \frac{T + a - 1}{n + a + b - 2} = \frac{T}{n} = 0.08. \quad (14)$$

Plotamos então, na fig. 2 o gráfico das distribuições a priori e posteriori com estas 3 configurações de hiperparâmetros. No caso da Priori 1, como ela possui moda próxima ao valor de EMV, a Posteriori 1 ficou bastante similar à Posteriori 3. Já a Priori 2 está distante da EMV. Então, ela exerce maior influência na inferência “puxando” a Posteriori 2 para a direita (em relação às posteriores 1 e 3).